# BRECHA DIGITAL Y POBREZA MULTIDIMENSIONAL EN COLOMBIA

JUAN JOSÉ DELGADO, JUAN PABLO SANCHEZ,NATALIA VARGAS

# ÍNDICE


- PREGUNTA DE INVESTIGACIÓN
- FUENTES DE DATOS
- CARGA E INTEGRACIÓN
- DICCIONARIO DE VARIABLES
- LIMPIEZA Y TRANSFORMACIÓN
- DATASET FINAL Y PRÓXIMOS PASOS

# ¿ESTAR DESCONECTADO IMPLICA MAYOR RIESGO DE POBREZA?

# 1– FUENTES DE DATOS

# FUENTE DE DATOS

Se utilizaron tres fuentes de datos provenientes de la Encuesta de Calidad de Vida ( ECV 2023) del DANE, el módulo de tecnologías de Información y Comunicación, el de Datos de la Vivienda y el archivo de Hogares con el Índice de Pobreza Multidimensional.Cada archivo presenta estructuras y separadores distintos, lo que hace necesario un tratamiento cuidadoso para su correcta utilización.Estas bases permiten capturar información sobre acceso digital, condiciones del hogar y niveles de pobreza, constituyendo el insumo principal del análisis.

| Archivo fuente | Separador | Contenido |
|---|---|---|
| Tecnologías de información y comunicación.CSV | Punto y coma (;) | Variables TIC del hogar - ECV 2023 |
| Datos de la vivienda.CSV | Punto y coma (;) | Zona urbana/rural – ECV 2023 |
| hogares_2023_dpto.CSV | Coma (,) | Índice de Pobreza Multidimensional por departamento – IPM 2023 |

# 2 – CARGA E INTEGRACIÓN

# CARGA E INTEGRACIÓN

En esta etapa se realizó la carga de las bases de datos respetando sus diferentes formatos y separadores, seguida de la estandarización de los nombres de las variables y la conversión de la llave **Directorio** a un formato común. Posteriormente, se integraron las bases mediante un cruce tipo Inner join, construyendo así una base unificada de hogares. Este proceso incluyó decisiones metodológicas clave para evitar errores silenciosos y garantizar la consistencia de la información.

```
import pandas as pd

# 1. Cargar TIC y Vivienda con punto y coma (;)
df_tic      = pd.read_csv('Tecnologías de información y comunicación.CSV',
                          sep=';', encoding='latin-1')
df_vivienda = pd.read_csv('Datos de la vivienda.CSV', sep=';', encoding='latin-1')

# 2. Cargar IPM con COMA (,) — formato distinto al de los otros módulos
df_ipm = pd.read_csv('hogares_2023_dpto.CSV', sep=',', encoding='latin-1')

# 3. Normalizar nombres de columnas a MAYÚSCULAS y sin espacios
df_tic.columns      = df_tic.columns.str.upper().str.strip()
df_vivienda.columns = df_vivienda.columns.str.upper().str.strip()
df_ipm.columns      = df_ipm.columns.str.upper().str.strip()

# 4. Asegurar que DIRECTORIO sea texto en todas
for d in [df_tic, df_vivienda, df_ipm]:
    d['DIRECTORIO'] = d['DIRECTORIO'].astype(str).str.strip()

# 5. El Gran Cruce — verificación condicional de CLASE
cols_vivienda = ['DIRECTORIO','CLASE'] if 'CLASE' in df_vivienda.columns \
                else ['DIRECTORIO']
df_temp  = pd.merge(df_tic, df_vivienda[cols_vivienda],
                    on='DIRECTORIO', how='inner')
df_final = pd.merge(df_temp, df_ipm[['DIRECTORIO','POBRE']],
                    on='DIRECTORIO', how='inner')

print(f'Filas finales para el modelo: {df_final.shape[0]}')
print(f'Nulos en POBRE: {df_final["POBRE"].isnull().sum()}')
```

# 3 – DICCIONARIOS DE VARIABLES

# DICCIONARIO DE VARIABLES

Se implementó un diccionario de variables que traduce los códigos técnicos del DANE en etiquetas claras e interpretables, facilitando el ánalisis económico de los datos. Este proceso permite agrupar las variables en dimensiones relevantes de la brecha digital, como acceso, uso de internet, habilidades digitales, costos y ubicación geográfica, haciendo posible interpretar posteriormente los resultados de los modelos de forma más intuitiva.

| Dimensión de brecha | Variables incluidas | Códigos DANE |
|---|---|---|
| Acceso y dispositivos | Smartphone, internet en hogar/trabajo, tipo de dispositivo | P1082, P1085, P765 |
| Uso productivo vs. recreativo | Correos, llamadas laborales, banca, trámites, educación | P1083Sxx, P1080Sxx |
| Habilidades digitales | 12 competencias: texto, seguridad, programación, privacidad | P1710Sxx |
| Costo y telefonía | Valor pagado por servicio de telefonía celular | P803S1 |
| Zona geográfica | Urbano / rural | CLASE |

# 4–LIMPIEZA Y TRANSFORMACIÓN

# LIMPIEZA Y TRANSFORMACIÓN

En esta fase se eliminaron variables irrelevantes, se corrigieron duplicados y se estandarizó el formato de los datos. Además, se recodificaron variables binarias, se trataron valores faltantes y se transformaron variables para mejorar su interpretación. También se construyeron variables clave, como indicadores de intensidad de uso de tecnologías y los tres pilares de la brecha digital: costo, cobertura, habilidades, fundamentales para el ánalisis posterior.

```
Limpieza completada sin errores de duplicidad.
========================================
BASE LISTA PARA EL RANDOM FOREST
========================================
Variable Objetivo:      POBRE
Total Predictores (X):   63
Total de Registros:      225.637
Variables de Intensidad: ['Intensidad Frec Uso PC Escritorio',
                          'Intensidad Frec Uso Laptop',
                          'Intensidad Frec Uso Tableta']
Variables de Brecha:     ['Brecha de Internet por Costo',
                          'Brecha de Internet por Cobertura',
                          'Brecha de Internet por Habilidad']
========================================
```

# 5 – DATASET FINAL Y PRÓXIMOS PASOS

# DATASET FINAL Y PRÓXIMOS PASOS

Como resultado del proceso, se obtuvo un dataset final compuesto por 225.637 hogares y 63 variables predictorias, con la pobreza multidimensional como variables objetivo. Esta base integra múltiples dimensiones de la brecha digital y se encuentra lista para su uso en modelos de Machine Learning. En las siguientes estapas, se realizara el balanceo de clases mediantes ténicas como el entrenamiento de un modelo Random Forest, con el fin de evaluar la relación entre inclusión digital y oibreza en Colombia

| Parámetro | Valor |
|---|---|
| Fuente | ECV 2023 - DANE (módulos TIC, Vivienda)<br>IPM 2023 - DANE (módulo pobre) |
| Registros tras cruce | 225.637 hogares |
| Predictores finales (X) | 63 variables digitales |
| Variable objetivo (y) | POBRE — Índice de Pobreza Multidimensional |
| Variables de intensidad construidas | 3 (PC, Laptop, Tableta) |
| Pilares de brecha construidos | 3 (Costo, Cobertura, Habilidad) |
| División entrenamiento/prueba | 80% / 20% \| random_state=42 |
| Software | Python 3.12 — pandas, numpy, scikit-learn |
| Próxima fase | SMOTETomek + Random Forest (1.000 árboles, umbral 0,70) |

# GRACIAS!